

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет об исследовательском проекте

на тему Обучение ретривера на инструкциях
(промежуточный, этап 1)

Выполнен студентом:

Группы #БПМИ246

Угрюмов Никита Викторович
(ФИО студента)

Проверен руководителем проекта:

Андреева Дарья Александровна, -
ФИО, научная степень (если есть)

Старший инженер нейронных сетей
Должность

ООО «ИТ ИКС 5 ТЕХНОЛОГИИ»
Место работы (организация или департамент НИУ ВШЭ)

Москва 2026

Содержание

Аннотация	2
1 Введение	2
2 Цели и задачи	2
2.1 Цель работы	2
2.2 Задачи	3
3 Актуальность	3
4 Обзор литературы	4
5 Результаты первых экспериментов	5
5.1 Описание собранного датасета	5
5.2 Бейзлайн: multilingual-e5-base на mMARCO	5
6 План дальнейшей работы	6

Аннотация

В данной работе исследуется возможность адаптации методологии Promptriever для русского языка. Promptriever - первый bi-encoder ретривер, способный следовать инструкциям на естественном языке при определении релевантности документов. Планируется базовый bi-encoder, изначально не способный следовать инструкциям, дообучить на русскоязычном датасете mMARCO с синтетически сгенерированными инструкциями и instruction negatives. Ожидаемый результат - улучшение метрик на запросах с инструкциями.

Ключевые слова: information retrieval, bi-encoder, instruction following, contrastive learning, mMARCO

1 Введение

Современные системы информационного поиска (Information Retrieval) активно используют нейросетевые модели для представления текстов в виде эмбедингов - векторов, кодирующих смысл текста. Архитектура bi-encoder позволяет независимо кодировать запросы и документы, что делает возможным предварительное вычисление эмбедингов документов, а затем эффективный поиск релевантных запросу документов [6].

Однако стандартные bi-encoder ретриверы после обучения теряют способность следовать инструкциям, даже если их архитектурной основой являются языковые модели, изначально обладавшие этой способностью [1].

В работе Weller et al. [1] представлен Promptriever - первый bi-encoder ретривер, способный учитывать инструкции на естественном языке при поиске. Авторы показали, что их подход приносит прирост ключевых метрик на бенчмарках FollowIR [2] и InstructIR [3]. Ключевой идеей является добавление инструкций к запросу, а также генерация instruction negatives - документов, релевантных запросу по теме, но не удовлетворяющих условию данной инструкции.

Оригинальная работа проводилась с данными на английском языке с использованием MS Marco [17]. Целью данного проекта является адаптация методологии Promptriever для русского языка с использованием мультязычного датасета mMARCO [4] и проверка гипотезы о переносимости подхода на русский язык.

2 Цели и задачи

2.1 Цель работы

Проверить гипотезу о том, что дообучение bi-encoder ретривера на русскоязычных данных с инструкциями и instruction negatives приведёт к улучшению метрик на запросах с инструкциями (p-MRR) без значительной деградации на стандартных запросах (MRR, nDCG).

2.2 Задачи

1. Изучение оригинальной статьи Promptriever и смежных работ (FollowIR, InstructIR, E5)
2. Подготовка данных:
 - (a) Сэмплирование 25-50k запросов из русской части mMARCO
 - (b) Синтетическая генерация инструкций, `positive_passage` (возможно, придется генерировать, если инструкция поломала релевантность) и `instruction negatives` через LLM
 - (c) Чистка пустых, битых строк
 - (d) Фильтрация текстов на не русском языке
 - (e) Дедупликация
 - (f) Фильтрация слишком коротких/длинных чанков
3. Замер бейзлайна multilingual-e5-base на mMARCO dev set
4. Дообучение bi-encoder с contrastive loss на собранном датасете
5. Оценка качества:
 - (a) Сбор golden-сета
 - (b) Метрики IR: MRR@k, nDCG@k, Recall@k
 - (c) Метрики instruction following: p-MRR (pairwise MRR)
 - (d) Анализ чувствительности к формулировке инструкций
6. Аблейшены: вклад `instruction negatives`, влияние размера обучающей выборки

3 Актуальность

Ретриверы являются неотъемлемой частью современных RAG-систем (Retrieval-Augmented Generation) [9]. Качество Retrieval этапа напрямую влияет на качество итогового ответа: если мы не нашли релевантный документ, то генератор в своем ответе упустит важную информацию.

Тем не менее, большинство ретриверов с архитектурой bi-encoder плохо понимают явные инструкции в запросе. В качестве второго этапа retrieval зачастую используют переранжирование через cross-encoder'ы, но это долго и дорого, поэтому в любом случае необходим хороший bi-encoder, умеющий следовать инструкциям, чтобы сузить область переранжирования.

4 Обзор литературы

Традиционные методы информационного поиска, такие как BM25 [8], ищут документы по статистике вхождения слов и не понимают смысл текста. Это ограничение привело к развитию нейросетевых подходов.

Архитектура bi-encoder позволяет независимо кодировать запросы и документы в единое векторное пространство с помощью нейросети-энкодера. Релевантность документа запросу можно оценить как скалярное произведение их эмбеддингов. При этом эмбеддинги документов можно посчитать заранее и затем для запроса оптимально искать релевантные документы, например, через FAISS [12]. DPR [7] показал, что bi-encoder хорошо работает на open-domain QA при обучении с contrastive loss, обгоняя классические sparse retrieval подходы

Среди современных bi-encoder моделей выделяется семейство E5 [5]. Модель multilingual-e5-base основана на xlm-roberta-base [13] и дообучена на мультязычных данных с contrastive loss. Она поддерживает более 100 языков, включая русский, имеет 12 слоёв, размерность эмбеддинга 768 и контекст 512 токенов. В данной работе планирую использовать как базовую модель, которую буду дообучать.

Однако стандартные bi-encoder, даже основанные на LLM, теряют способность следовать инструкциям после обучения. Ранние попытки решить эту проблему - TART [11] и INSTRUCTOR [10] - использовали довольно простой подход - добавление одинаковых инструкций для одного типа задач, но это не способствует следованию инструкций в реальных условиях, ведь нет инструкций, зависящих от конкретного запроса. Оценивать данную способность можно с помощью бенчмарков FollowIR [2] и InstructIR [3], где введена метрика p-MRR, измеряющая изменение ранжирования при смене инструкции

Promptriever [1] - первый bi-encoder, который умеет следовать инструкциям. Ключевая идея состоит в генерации инструкций для каждого запроса таким образом, чтобы они не ухудшали релевантность изначального positive passage. Но для достижения цели авторы также добавляют в датасет instruction negatives - документы, релевантные по теме, но не подходящие под условие инструкции, что помогает научить модель действительно учитывать инструкции. В качестве базовой модели используется LLaMA-2 7B [15], поскольку LLM изначально обладают способностью следовать инструкциям. Датасет для обучения содержит около 500k примеров из MS MARCO, инструкции сгенерированы с помощью Llama 3 70B Instruct [16], а instruction negatives с помощью gpt-4o [1, 14].

Для адаптации подхода на русский язык в данной работе используется mMARCO [4] - мультязычная версия MS MARCO passage ranking с автоматическими переводами на 14 языков. Русская часть содержит около 800к запросов в train части.

5 Результаты первых экспериментов

5.1 Описание собранного датасета

Для первых экспериментов выполнены следующие шаги:

1. Загружена русская часть mMARCO с HuggingFace (unicamp-dl/mmarco)
2. Для 500 примеров сгенерированы инструкции и instruction negatives с помощью модели Llama-3.1-8B-Instruct [16].

Пример сгенерированных данных:

Таблица 1: Пример сгенерированной инструкции и instruction negative

Поле	Значение
Query	какой самый известный фильм, в котором снимался Чак Норрис?
Instruction	Документ релевантен, если это справка об актёре Чак Норрисе, где перечисляются несколько его художественных фильмов и указаны годы выхода
Instruction Negative	Одним из самых известных фильмов с участием Чака Норриса часто называют «The Delta Force»... (без списка фильмов с годами)

5.2 Бейзлайн: multilingual-e5-base на mMARCO

Проведено тестирование модели intfloat/multilingual-e5-base на:

1. русской части mMARCO dev (500 запросов, 200 кандидатов на запрос из BM25 scoredocs) - брал не все запросы и документы из-за медленной скорости работы. Для каждого запроса переранжировал 200 кандидатов через e5
2. Собранном датасете
это тоже подмножество из 500 (уже других) запросов mMARCO dev, но тут я в качестве базы документов брал для каждого документа positive_passage, hard_negative и сгенерированный instruction negative (то есть всего 1500 документов)

Таблица 2: Результаты бейзлайнов на русской части mMARCO dev

Модель	MRR@10	nDCG@10	Recall@10
BM25	0.088	0.11	0.17
multilingual-e5-base (rerank bm25)	0.146	0.171	0.266

Таблица 3: Собранный датасет, влияние добавления инструкций к запросу (E5 без дообучения)

Режим запроса	MRR@10	Recall@5
query	0.754	1.000
query + instruction	0.672	0.970

Добавление инструкции к запросу ухудшает метрики у модели без специального обучения. Это может говорить о двух вещах:

1. стандартная E5 не обучена следовать инструкциям и воспринимает дополнительный текст как шум
2. после генерации инструкции `positive_passage` перестал быть релевантным

6 План дальнейшей работы

1. Масштабирование генерации данных:

- (a) Увеличить выборку до 25–50k запросов
- (b) Использовать более мощные модели для генерации качественных инструкций
- (c) Добавить фильтрацию сгенерированных данных

2. Дообучение ретривера:

- (a) Дообучить базовую модель (multilingual-e5-base).
- (b) Провести эксперименты с различными гиперпараметрами обучения (learning rate, batch size).

3. Оценка:

- (a) Создание golden set с полуручной разметкой
- (b) Метрики: MRR, nDCG, p-MRR
- (c) Анализ чувствительности к перефразированию инструкций

4. Аблейшены:

- (a) Оценка вклада `instruction negatives` в итоговое качество.
- (b) Исследование влияния размера обучающей выборки на метрики.

Список литературы

- [1] O. Weller, B. Van Durme, D. Lawrie, A. Paranjape, Y. Zhang, and J. Hessel, "Promptriever: Instruction-Trained Retrievers Can Be Prompted Like Language Models," *arXiv preprint arXiv:2409.11136*, 2024.
- [2] O. Weller, B. Chang, S. MacAvaney, K. Lo, A. Cohan, B. Van Durme, D. Lawrie, and L. Soldaini, "FollowIR: Evaluating and Teaching Information Retrieval Models to Follow Instructions," *arXiv preprint arXiv:2403.15246*, 2024.
- [3] H. Oh, H. Lee, S. Ye, H. Shin, H. Jang, C. Jun, and M. Seo, "InstructIR: A Benchmark for Instruction Following of Information Retrieval Models," *arXiv preprint arXiv:2402.14334*, 2024.
- [4] L. Bonifacio, V. Jeronymo, H. Q. Abonizio, I. Campiotti, M. Fadaee, R. Lotufo, and R. Nogueira, "mMARCO: A Multilingual Version of the MS MARCO Passage Ranking Dataset," *arXiv preprint arXiv:2108.13897*, 2021.
- [5] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 Text Embeddings: A Technical Report," *arXiv preprint arXiv:2402.05672*, 2024.
- [6] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," in *Proceedings of EMNLP-IJCNLP*, 2019, pp. 3982–3992.
- [7] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, "Dense Passage Retrieval for Open-Domain Question Answering," in *Proceedings of EMNLP*, 2020, pp. 6769–6781.
- [8] S. E. Robertson, S. Walker, S. Jones, M. M. Hancock-Beaulieu, and M. Gatford, "Okapi at TREC-3," in *NIST Special Publication*, 1995.
- [9] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.
- [10] H. Su, W. Shi, J. Kasai, Y. Wang, Y. Hu, M. Ostendorf, W.-t. Yih, N. A. Smith, L. Zettlemoyer, and T. Yu, "One Embedder, Any Task: Instruction-Finetuned Text Embeddings," *arXiv preprint arXiv:2212.09741*, 2022.
- [11] A. Asai, T. Schick, P. Lewis, X. Chen, G. Izacard, S. Riedel, H. Hajishirzi, and W.-t. Yih, "Task-aware Retrieval with Instructions," *arXiv preprint arXiv:2211.09260*, 2022.
- [12] J. Johnson, M. Douze, and H. Jégou, "Billion-scale similarity search with GPUs," *arXiv preprint arXiv:1702.08734*, 2017.

- [13] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, "Unsupervised Cross-lingual Representation Learning at Scale," in *Proceedings of ACL*, 2020, pp. 8440–8451.
- [14] OpenAI, "GPT-4 Technical Report," *arXiv preprint arXiv:2303.08774*, 2023.
- [15] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale, et al., "Llama 2: Open Foundation and Fine-Tuned Chat Models," *arXiv preprint arXiv:2307.09288*, 2023.
- [16] A. Dubey, A. Jauhri, A. Pandey, A. Kadian, I. Al-Dahle, A. Letak, A. Mathur, A. Schelten, A. Yang, A. Fan, et al., "The Llama 3 Herd of Models," *arXiv preprint arXiv:2407.21783*, 2024.
- [17] P. Bajaj et al., "MS MARCO: A Human Generated MACHine Reading COMprehension Dataset," *arXiv preprint arXiv:1611.09268*, 2016.